

Министерство науки и высшего образования Российской Федерации
Муромский институт (филиал)
федерального государственного бюджетного образовательного учреждения высшего образования
**«Владимирский государственный университет
имени Александра Григорьевича и Николая Григорьевича Столетовых»**
(МИ ВлГУ)

Факультет _____ ИТР _____

Кафедра _____ ФПМ _____

УТВЕРЖДАЮ

Заведующий кафедрой

_____ А.А. Орлов
(подпись)

« _____ » _____ 2026 г.

БАКАЛАВРСКАЯ РАБОТА

Тема: «Разработка системы автоматической категоризации и семантического сопоставления потребительских товаров по неструктурированным текстовым описаниям с использованием методов анализа естественного языка»

_____ МИВУ.01.03.02-05.000 БР _____

Руководитель

Абрамова Е.С.
(фамилия, инициалы)

_____ (подпись) _____ (дата)

Студент ПМИ-122
(группа)

Косолапова Е.А.
(фамилия, инициалы)

_____ (подпись) _____ (дата)

Муром 2026

БЛАНК ЗАДАНИЯ

В бакалаврской работе разработана система автоматической категоризации и семантического сопоставления потребительских товаров по неструктурированным текстовым описаниям с использованием методов анализа естественного языка. Система, основанная на языковой модели–трансформере `rubert-tiny2`, реализует функции первичной лингвистической предобработки, вычисления плотных векторов контекстуального внимания и иерархической каскадной классификации. Для поиска аналогов и устранения дублирования позиций интегрирован алгоритм приближенного поиска ближайших соседей на графах HNSW с применением разработанного метода адаптивного сужения семантического пространства. Программный прототип реализован на языке Python с использованием библиотек CatBoost, FAISS, OpenPyXL и глубокого обучения PyTorch, что обеспечивает потоковую обработку текстовых данных в режиме реального времени и прямую интеграцию с локальными файлами табличного формата.

The Bachelor's thesis presents the development of a system for automated categorization and semantic matching of consumer goods based on unstructured textual descriptions using natural language processing techniques. The system, utilizing the ruBERT-tiny2 transformer language model, implements functions for primary linguistic preprocessing, dense contextual attention vector computation, and hierarchical cascade classification. To detect analogues and eliminate duplicate entries, an approximate nearest neighbor search algorithm on HNSW graphs is integrated, leveraging the developed method for adaptive space truncation. The software prototype is implemented in Python using the CatBoost, FAISS, OpenPyXL, and PyTorch deep learning libraries, ensuring real-time streaming data processing and direct integration with local spreadsheet files.

Министерство науки и высшего образования Российской Федерации
Муромский институт (филиал)
федерального государственного бюджетного образовательного учреждения высшего образования
**«Владимирский государственный университет
имени Александра Григорьевича и Николая Григорьевича Столетовых»**
(МИ ВлГУ)

Факультет _____ ИТР _____

Кафедра _____ ФПМ _____

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

Тема: «Разработка системы автоматической категоризации и семантического сопоставления потребительских товаров по неструктурированным текстовым описаниям с использованием методов анализа естественного языка»

МИВУ.01.03.02-05.000 ПЗ

Муром 2026

Содержание

Введение	7
1 Аналитический обзор технического задания	10
1.1 Обзор задачи категоризации и семантического сопоставления товаров ...	10
1.3 Обзор методов предобработки текстовых описаний	22
2. Проектирование системы автоматической категоризации и семантического сопоставления товаров	25
2.1 Формальная постановка задачи автоматизации категоризации и сопоставления	25
2.3 Математическая модель векторизации на основе механизма внимания ...	30
2.4 Математическая модель классификации категорий товаров	32
2.5 Математическая модель семантического сопоставления	35
2.6 Обоснование и описание архитектуры системы	36
3.1 Подготовка набора данных и описание экспериментальной среды	47
3.2 Методика проведения экспериментов	53
3.3 Результаты экспериментов и их анализ	56
Заключение	61
Список использованной литературы	62

					МИВУ.01.03.02-05.000				ПЗ				
Изм	Лист	№ докум.	Подп.	Дата									
Студент	Косолапова Е.А.				«Разработка системы автоматической категоризации и семантического сопоставления потребительских товаров по неструктурированным текстовым описаниям с использованием методов анализа естественного языка»				Лит.	Лист	Листов		
Руков.	Абрамова Е.С.								у		6	62	
Конс.									МИ ВлГУ ПМИ-122				
Н.контр	Мареев А.В.												
Зав.каф.	Орлов А.А.												

Введение

Современный этап развития информационных технологий характеризуется стремительным увеличением объема информации, создаваемой людьми и машинами на естественном языке.

Электронная коммерция развивается и занимает все большую долю на рынке товаров и услуг. Согласно данным аналитического агентства Data Insight, объем рынка розничной интернет-торговли в России в 2023 году составил 7,9 трлн рублей, показав рост на 48% в годовом исчислении [1]. Столь стремительное масштабирование отрасли подтверждает необходимость автоматизации процессов обработки товарных данных. Каждый день на маркетплейсах появляется множество новых товарных позиций, каждая из которых сопровождается текстовым описанием. Проблема в том, что эти описания часто бывают неструктурированными, содержат опечатки, сокращения и нетипичные формулировки, что существенно затрудняет обработку товарных данных.

В большинстве интернет-магазинов и маркетплейсов процесс категоризации товаров до сих пор выполняется вручную. Операторы анализируют текстовое описание товара и относят его к определенной категории внутреннему классификатору предприятия. Такой подход имеет ряд существенных недостатков: низкую производительность, субъективность решений и высокую трудоемкость при обработке больших объемов данных.

Актуальность работы обусловлена несколькими факторами. Во-первых, необходима автоматизация трудоемкого процесса ручной классификации товаров. Во-вторых, существующие гибридные системы недостаточно эффективно сочетают семантическое понимание текста с соблюдением бизнес-логики. В-третьих, сохраняется потребность в решениях, устойчивых к шуму в реальных текстовых описаниях товаров.

					МИВУ.01.03.02-05.000	ПЗ	Лист
Изм	Лист	№ докум.	Подп.	Дата			7

Объектом исследования являются процессы автоматической категоризации и семантического сопоставления неструктурированных текстовых описаний потребительских товаров.

Предметом исследования являются математические модели векторизации текстов на основе архитектуры Transformer (rubert-tiny2), метод градиентного бустинга для классификации товарных категорий, реализованный в библиотеке CatBoost и алгоритмы приближенного поиска ближайших соседей (HNSW) для семантического сопоставления товарных описаний с использованием библиотеки FAISS [2, 3, 4].

Целью работы является разработка системы автоматической категоризации и семантического сопоставления товаров с использованием методов анализа естественного языка, обеспечивающей высокую точность отнесения неструктурированных текстовых описаний к заданным категориям товаров.

Для достижения поставленной цели будут выполнены следующие задачи:

- 1) провести анализ предметной области и существующих решений;
- 2) выполнить формальную математическую постановку задачи;
- 3) исследовать и обоснованно выбрать методы векторизации, классификации и сопоставления данных;
- 4) спроектировать архитектуру программной системы;
- 5) сформировать и подготовить набор данных для экспериментов;
- 6) реализовать прототип системы и провести оценку качества на основе метрик качества обучения.

Первый раздел работы содержит аналитический обзор предметной области, описание задач категоризации и семантического сопоставления потребительских товаров, а также сравнительный анализ существующих систем и методов обработки текстовых данных.

Второй раздел описывает проектирование архитектуры системы, построение математических моделей процессов векторизации и классификации

текстовых данных, а также обоснование выбора методов и алгоритмов (rubert–tiny2, CatBoost, FAISS).

Третий раздел посвящен проведению экспериментального исследования разработанного решения, описанию характеристик набора данных, настройке программной среды и анализу полученных результатов на основе выбранных метрик качества.

1 Аналитический обзор технического задания

1.1 Обзор задачи категоризации и семантического сопоставления товаров

В рамках автоматизации обработки товарных данных выделяют две самостоятельные технологические задачи, имеющие разные цели и математический аппарат: автоматическую категоризацию и семантическое сопоставление.

Категоризация представляет собой задачу многоклассовой классификации, целью которой является отнесение новой номенклатурной единицы к одному из заранее определенных узлов иерархического справочника (например, отнесение позиции «BIC Round Stic» к категории «Канцелярские товары», сегменту «Ручки» и типу «Шариковые»). Результатом здесь является конкретная метка класса.

Семантическое сопоставление направлено на выявление идентичности или степени сходства между двумя объектами в условиях отсутствия единых идентификаторов. В отличие от категоризации, здесь целью является не поиск категории, а нахождение дубликатов или аналогов в базе данных (например, сопоставление записей «iPhone 15 128Gb» и «Смартфон Apple 15»). Результатом задачи является мера близости векторов в многомерном пространстве и принятие решения на основе установленного порога сходства.

Однако для успешного сопоставления объектов внутри системы необходимо зафиксировать целевую структуру, в которую будут проецироваться входящие данные. Для формализации внутренней структуры данных и автоматизации процессов каталогизации в рамках исследуемой информационной системы была разработана многоуровневая иерархическая модель товарного справочника. Архитектура иерархии включает в себя три последовательных уровня вложенности, а также атомарный уровень технических характеристик, определяющих уникальные свойства позиций.

Разработанный классификатор позволяет не только систематизировать номенклатурные позиции, но и эффективно собирать сопутствующие характеристики для каждого типа продукции в единую структуру.

Пример логической структуры разработанного иерархического справочника представлен на рисунке 1.




Рисунок 1 – Логическая структура наполнения товарного справочника

Необходимость автоматизации данных процессов обусловлена переходом электронной коммерции к модели бесконечной полки, подразумевающей наличие неограниченного виртуального ассортимента товаров. Традиционные офлайн–магазины ограничены физической площадью, заставляющей их фокусироваться на ходовых товарах, в то время как онлайн–торговля через цифровые платформы предлагает неограниченный ассортимент, обеспечивая доступ к нишевым продуктам [1].

На этапе сбора и агрегации данных такая запись определяется как входящая номенклатура (ВХН) [5]. ВХН позиции, как правило, представляют собой неструктурированный текст, содержащий специфические аббревиатуры и опечатки. Следовательно, для автоматизации процессов сопоставления требуется предварительная сегментация – процедура выделения из «сырой» текстовой строки набора дискретных атрибутов и значимых характеристик [6].

Качество автоматической категоризации товаров определяется надежностью предварительной обработки текстовых описаний. Базовой единицей учета в таких системах выступает номенклатурная позиция, или складская единица учета (SKU), представляющую собой текстовую строку,

содержащую структурированное описание товара и его метаданных в информационной базе предприятия [7].

Процесс преобразования неструктурированных описаний подразумевает участие нескольких функциональных ролей. Операторы обработки данных выполняют первичную семантическую сегментацию и идентификацию категорий, что критично для минимизации статистических погрешностей. Специалисты по интеграции данных обеспечивают нормализацию форматов и загрузку массивов в аналитические хранилища, поддерживая высокую пропускную способность системы. Завершают цепочку клиентские менеджеры, определяющие требования к детализации атрибутов и формирующие управленческую отчетность.

Роли участников процесса и сложность обработки ВХН обусловлены широтой прикладных задач. Применение автоматизированных методов обработки ВХН находит отражение в решении ряда задач, среди которых наиболее значимыми являются:

- сопоставление идентичных товаров: в экосистемах маркетплейсов структурированные данные позволяют объединять предложения от поставщиков в общие карточки и обеспечивать корректную работу поисковых фильтров;

- идентификация и верификация позиций в справочниках: в системах электронного документооборота автоматизация позволяет сопоставлять номенклатуру из первичных документов с внутренним классификатором компании, исключая дублирование при заполнении складских баз данных;

- семантический поиск и подбор аналогов: в закупочных процедурах и тендерах автоматизированное сравнение характеристик используется для поиска наиболее выгодных предложений при несовпадении текстовых формулировок в спецификациях поставщиков;

- формирование векторных представлений объектов: в рекомендательных системах извлечение полного набора атрибутов товара служит основой для

создания математических моделей, на базе которых работают алгоритмы персонализированной выдачи.

Для корректного решения этих задач важно учитывать внутреннюю структуру данных. Несмотря на внешнюю хаотичность, любая входящая номенклатура объективно содержит в себе ряд типовых компонентов, выделение которых и является целью семантического анализа.

Основу этой структуры составляет категория, представляющая собой самый масштабный уровень классификации и объединяющая товары по общему функциональному назначению. Именно она определяет глобальный контекст и набор правил для всех вложенных элементов. Более детальная группировка происходит на уровне сегмента, в рамках которого определяется основной состав значимых характеристик, подлежащих извлечению из текстовой строки. Конечной точкой классификации выступает тип товара, определяющий конкретный вид изделия; точность на данном этапе критически важна, так как ошибки здесь приводят к неверному сопоставлению аналогов.

Наряду с иерархическими уровнями, ключевую роль в идентификации происхождения товара играют производитель и бренд. Эти связанные сущности характеризуются наличием зависимостей между основным брендом и его саббрендами, что позволяет использовать их как опорные точки при автоматическом распознавании. Непосредственные свойства изделий описываются через технические характеристики, при этом список значимых атрибутов напрямую зависит от категории: например, оттенки важны для сегментов ручек и маркеров, но могут быть избыточными для других групп товаров. Специфика входящей номенклатуры подразумевает наличие информационного шума и сокращений, которые включают служебные метаданные. Хотя такие элементы не несут семантической нагрузки для категоризации, они требуют корректной нормализации.

Таким образом, структура товарных данных представляет собой сложную иерархическую систему, где каждый уровень накладывает свои ограничения на допустимые значения атрибутов.

					МИВУ.01.03.02-05.000	ПЗ	Лист
Изм	Лист	№ докум.	Подп.	Дата			13

Несмотря на наличие регламентов и методического материала, ручная обработка входящей номенклатуры сопряжена с рядом трудностей, обусловленных низким качеством исходных текстовых описаний [8]. Анализ данных позволяет классифицировать факторы, осложняющие идентификацию и сегментацию товаров:

Основными факторами, осложняющими автоматическую идентификацию, являются высокая вариативность написания и избыточность текстовых строк. Наличие специфических сокращений и аббревиатур, таких как «мех. кар.», требует глубокого понимания контекста предметной области. Дополнительную сложность вносят опечатки, семантический шум, а также смешение кириллицы и латиницы в названиях брендов, что делает невозможным применение простых алгоритмов жесткой фильтрации [6, 9].

Наличие перечисленных проблем приводит к тому, что ручная классификация критического объема товарных позиций становится экономически нецелесообразной и сопровождается высоким процентом ошибок. Ошибки допущенные на этапе сегментации транслируются на все последующие этапы обработки данных, искажая аналитику и приводя к возвратам товаров.

Если компания работает с ограниченным ассортиментом популярных позиций, она может выделять ресурсы на качественное информационное наполнение каждого товара. Такие затраты окупаются за счёт высокого объёма продаж. Однако при расширении каталога за счёт товаров низкого спроса традиционный подход становится неэффективным. [1].

Таким образом, ручная обработка товарных данных не позволяет масштабировать бизнес из-за высокой трудоёмкости и подверженности ошибкам. Для автоматизации этих процессов необходимо применение методов анализа естественного языка, обеспечивающих очистку текста от шума, восстановление сокращений и корректное распределение товаров по категориям.

1.2 Анализ существующих решений в области категоризации товаров

В современной практике обработки товарных данных для первичной очистки массивов и детерминированного извлечения формальных характеристик традиционно применяются регулярные выражения [10].

Данный подход позволяет находить стандартные физические параметры по заранее заданным шаблонам, однако их использование ограничено негибкостью к опечаткам и вариативности данных, так как механизм сопоставления основан на строгом соответствии шаблону и не допускает отклонений, вызванных, например, опечатками. Также проблемой является сложность поддержки, потому что при увеличении вариативности данных количество необходимых шаблонов растет, что приводит к созданию громоздких и труднообновляемых алгоритмов. Наконец, отсутствие семантического анализа требует прописывания точных правил для отличия сокращений от прочих сочетаний букв.

Более сложным этапом автоматизации, развивавшимся до появления современных нейросетевых моделей, выступает метод статистической значимости слов TF-IDF [11]. Данная статистическая мера позволяет вычислять вес каждого термина, отсеивая лексические единицы, не несущие уникальной семантики.

Метод TF-IDF оценивает значимость термина как произведение частоты его употребления в конкретной строке и обратной частоты встречаемости во всем массиве данных. За счет отсеивания общеупотребительных лексических единиц, не несущих уникальной семантики, механизм эффективно выделяет ключевые слова. Однако метод обладает и некоторыми недостатками. К ним относится полное отсутствие семантического анализа, так как алгоритм учитывает только графическое написание слов и не способен распознавать синонимы. Также метод игнорирует контекст, что не позволяет устранять семантическую неоднозначность слов, имеющих разные значения в разных категориях. Кроме того, наблюдается низкая эффективность при выявлении

неявных связей между объектами в случае отсутствия их посимвольного совпадения.

Технологические подходы к автоматизации товарных каталогов можно разделить на готовые информационные системы и математические методы обработки данных. К первой группе относятся программные комплексы класса PIM и MDM, а также проприетарные алгоритмы маркетплейсов. Вторую группу составляют методы интеллектуального анализа текста.

В рамках программных решений маркетплейсов (Wildberries, Ozon и др.) применяются гибридные методы, сочетающие машинное обучение и бизнес–правила. Однако такие системы часто требуют ручной верификации и показывают низкую эффективность при обработке зашумленных номенклатур с нетипичными сокращениями.

Системы данного вида нацелены на быструю загрузку товаров в каталог площадки. В основе их функционирования лежит гибридный метод, сочетающий использование алгоритмов машинного обучения и предустановленных бизнес–правил. В процессе работы система анализирует предоставленное продавцом текстовое описание и сопоставляет его с внутренней иерархической структурой категорий маркетплейса. Несмотря на автоматизацию, такие решения имеют ряд существенных ограничений.

Во–первых, сохраняется необходимость ручной верификации данных, так согласно регламентам большинства площадок, автоматические алгоритмы выполняют лишь вспомогательную роль, оставляя окончательный выбор категории за пользователем.

Во–вторых, наблюдается низкая степень нормализации входящих данных. Алгоритмы показывают высокую эффективность только при работе с описаниями, заранее приведенными к стандартам платформы. При обработке зашумленных номенклатур, содержащих нетипичные сокращения или избыточную техническую информацию, точность распределения резко снижается из–за неспособности системы идентифицировать истинное значение слов в условиях высокого уровня информационного шума. Исследования

методов сопоставления объектов показывают, что традиционные подходы на основе жестких правил теряют до 30% точности при работе с зашумленными данными, что делает необходимым переход к глубоким семантическим моделям. На практике существующие гибридные системы часто сталкиваются с проблемой «холодного старта» (отсутствие эталонных описаний для новых товаров) для новых уникальных товаров и показывают низкую эффективность при отсутствии эталонных описаний в базе данных [9].

Проведенный анализ подтверждает, что существующие программные решения и классические алгоритмы не обеспечивают требуемой точности при работе с зашумленными входящими номенклатурами. Они либо требуют контроля со стороны операторов, либо не обладают необходимой гибкостью для распознавания смысла специфических сокращений и профессиональной лексики.

Это обосновывает необходимость разработки специализированного модуля, способного проводить глубокое семантическое сопоставление. Таким образом, перед применением любых алгоритмов классификации и сопоставления необходима предварительная нормализация текстовых описаний, которая рассматривается в следующем разделе.

Для устранения факторов, которые осложняют автоматическую обработку, необходимо применение комплекса методов предобработки. На этапе базовой очистки выполняется удаление неинформативных символов и приведение текста к нижнему регистру, что позволяет унифицировать написание и снизить размерность данных. Процесс токенизации разделяет текстовую последовательность на составляющие элементы, при этом используются алгоритмы, сохраняющие целостность технических параметров для избежания потери значимых характеристик.

Неотъемлемой частью процесса нормализации является унификация единиц измерения, так как в номенклатурах физические величины часто записываются вариативно, например, «мл», «ml» или «миллилитр». Без приведения таких сокращений к единому виду система воспринимает их как

разные токены, что ведет к избыточному росту словаря и снижению точности семантического сопоставления. Процедура нормализации позволяет восстановить полную форму единиц измерения, обеспечивая корректную работу алгоритмов при сравнении технических характеристик товаров. Далее, для приведения оставшихся слов к единой морфологической форме, применяются методы стемминга или лемматизации.

Также на данном этапе решается проблема смешанных алфавитов путем приведения к единому регистру, что критично для идентификации брендов, записанных одновременно кириллицей и латиницей. Последующая очистка текста ориентирована на сохранение контекстных связей, необходимых для корректной работы механизмов самовнимания трансформерных архитектур. В отличие от классических подходов, в рамках спроектированного конвейера не применяется удаление стоп-слов и глубокая лемматизация, поскольку предобученная модель ruBERT-tiny2 использует встроенный WordPiece-токенизатор. Это позволяет эффективно обрабатывать различные формы слов и синтаксические зависимости непосредственно на этапе субтокенизации, повышая качество семантического анализа [2, 12].

Использование данных методов в совокупности позволяет сформировать очищенный массив данных, на основе которого возможна эффективная реализация алгоритмов семантического сопоставления и векторизации.

Для применения математических алгоритмов классификации текстовых данных, прошедших предобработку, нужно преобразовать в числовые векторы. Выбор метода векторизации напрямую влияет на способность системы улавливать семантическую близость между товарами.

Обоснование выбора оптимального подхода и детальный сравнительный анализ рассматриваемых математических моделей векторизации текстовых данных по ключевым критериям эффективности наглядно представлены в таблице 1.

Таблица 1 – Сравнение методов векторизации

Критерий	TF-IDF	Word2Vec/FastText	rubert-tiny2
Принцип формирования вектора	Статистический	Дистрибутивная семантика	Динамический контекстный анализ
Учет семантики	Отсутствует, т.к. учитывает только частоту слов	Учитывает смысл слов и морфологию через n-граммы символов	Максимальный. Понимает контекст и смысловые зависимости даже в коротких фразах
Работа с опечатками и шумом	Неработоспособность при изменении даже одного символа	FastText может быть эффективен за счет работы с частями слов	Высокая устойчивость за счет разбиения слов на субтокены
Необходимость обучения	Не требует предварительного обучения на больших массивах данных	Требуется длительного предобучения на больших массивах данных	Предобучена, дообучение не требуется.

Для системы выбрана модель rubert-tiny2, сочетающая высокую точность анализа смысловой близости объектов с минимальными аппаратными требованиями [2]. В отличие от традиционных статистических подходов, данная модель сопоставляет товары даже при отсутствии прямых лексических совпадений, что важно для выявления скрытых дубликатов в каталоге.

Обработка текстовых данных обеспечивается за счет контекстуальной природы трансформеров. Модель интерпретирует многозначные термины, опираясь на сопутствующие характеристики, что минимизирует ошибки, характерные для работы со специфической номенклатурой.

Преимуществом данной архитектуры также является полная совместимость с инструментами семантического поиска. Эмбединги, формируемые rubert-tiny2, адаптированы для использования в библиотеке FAISS [13]. Такая связка позволяет проводить поиск аналогов в режиме реального времени даже на массивах данных, превышающих миллион позиций.

Решение задачи автоматизации обработки ВХН предполагает реализацию трехуровневого каскадного процесса классификации с последующим этапом семантического поиска, что обуславливает необходимость применения специфического набора алгоритмов.

В рамках разработанного каскада последовательно решаются задачи классификации, целью которых является поочередное определение принадлежности товара к конкретной категории, сегменту и типу. Использование линейных моделей (логистической регрессии) и вероятностных алгоритмов (наивного байесовского классификатора) в задачах категоризации ограничено их высокой чувствительностью к лексическому шуму и резким падением обобщающей способности при росте размерности пространства целевых классов [14].

Выбор конкретной реализации алгоритма градиентного бустинга проводился на основе сравнительного анализа наиболее распространенных библиотек, таких как XGBoost, LightGBM и CatBoost [15]. Основные характеристики алгоритмов представлены в таблице 2.

Таблица 2 – Сравнительный анализ библиотек градиентного бустинга

Критерий сравнения	XGBoost	LightGBM	CatBoost
Обработка категориальных признаков	Требуется внешнего кодирования	Требуется ручной настройки параметров категорий	Встроенная поддержка
Риск переобучения	Средний, так как чувствителен к гиперпараметрам	Высокий на малых выборках	Минимальный за счет использования симметричных деревьев
Работа с текстом	Требуется предварительной векторизации	Требуется предварительной векторизации	Поддерживает расчет текстовых признаков «из коробки»
Скорость обучения	Средняя	Высокая	Средняя
Точность на зашумленных данных	Средняя	Ниже среднего	Высокая

На основании данных, приведенных в таблице 2, среди программных библиотек для реализации выбран алгоритм, представленный в библиотеке CatBoost [3]. В отличие от аналогов, данный алгоритм обладает встроенной поддержкой категориальных признаков и не требует предварительного кодирования (например, One–Hot Encoding или Label Encoding), что

существенно сокращает объем предобработки данных и снижает риск переобучения на разреженных матрицах большого размера.

Кроме того, CatBoost использует модифицированную версию градиентного бустинга, устойчивую к переобучению при обучении на малых и средних выборках. Эти свойства делают CatBoost предпочтительным выбором для задачи классификации товарных описаний, где часть признаков (бренды, единицы измерения, материал) носят категориальный характер, а высокая размерность признакового пространства обуславливает необходимость применения встроенной регуляризации.

Второй этап заключается в семантическом сопоставлении объектов для выявления степени их идентичности.

В качестве меры семантической близости векторов выбрано косинусное сходство. Косинусная мера оценивает угол между векторами и инвариантна к их абсолютной длине, что принципиально важно при сравнении эмбеддингов, полученных путем извлечения вектора служебного токена (CLS).

Два текстовых описания различной длины могут порождать векторы с разной евклидовой нормой, но с одинаковым направлением в пространстве признаков; косинусное сходство корректно идентифицирует их как близкие по смыслу. Евклидово расстояние в данной ситуации давало бы завышенную оценку различия из-за разницы в длинах, а не в семантике.

При масштабировании системы на большие массивы данных прямой перебор пар становится вычислительно невозможным [16]. Для оптимизации процесса применяется алгоритм HNSW, реализованный в программной библиотеке FAISS [17]. Это обеспечивает высокую вычислительную эффективность и позволяет выполнять поиск в режиме, близком к реальному времени.

Таким образом, ни классические методы (регулярные выражения, TF-IDF), ни готовые системы маркетплейсов не обеспечивают требуемой точности на зашумлённых данных. Это обуславливает необходимость применения

современных контекстных моделей векторизации и градиентного бустинга, что и будет реализовано в предлагаемой системе.

1.3 Обзор методов предобработки текстовых описаний

Выбранная для векторизации модель rubert-tiny2 предъявляет высокие требования к качеству входных данных, поэтому необходима их многоэтапная предобработка [18]. Процесс трансформации входящей номенклатуры в очищенный вид начинается с этапа базовой очистки, который включает приведение текста к нижнему регистру и удаление неинформативных символов, таких как знаки пунктуации и спецсимволы. Это позволяет унифицировать написание и исключить влияние графического шума на процесс векторизации.

Следующим этапом является токенизация, представляющая собой разделение строки на отдельные смысловые единицы. При обработке товарных наименований используются специализированные алгоритмы, сохраняющие целостность технических артикулов и числовых параметров, что предотвращает потерю значимых характеристик. Для приведения различных словоформ к единому контекстному базису используется встроенный в модель rubert-tiny2 токенизатор WordPiece. В отличие от классических подходов, требующих применения сторонних библиотек морфологического анализа, современные трансформерные архитектуры не нуждаются в предварительной лемматизации. Механизм самовнимания нейросети эффективно обрабатывает слова во всех грамматических формах и падежах, сохраняя исходные синтаксические связи и семантическую целостность описания товаров.

Завершающим этапом конвейера выступает нормализация и унификация данных. На этом этапе осуществляется преобразование специфических сокращений в полную форму, а также приведение различных вариантов записи единиц измерения к единому стандарту. Данная последовательность операций позволяет существенно минимизировать размерность словаря и подготовить данные для формирования качественных эмбеддингов в модели rubert-tiny2.

В качестве иллюстрации описанных процедур рассматривается преобразование типичной исходной текстовой строки, содержащей сокращения, знаки препинания и смешанные алфавиты. В процессе очистки осуществляется приведение всех символов к нижнему регистру, удаление кавычек и знаков препинания, а также раскрытие аббревиатур и приведение единиц измерения к единому каноническому виду. Это позволяет сформировать стандартизированное описание, пригодное для корректной токенизации. Пример трансформации товарного описания после прохождения всех этапов предобработки представлен в таблице 3.

Таблица 3 – Пример предобработки товарной строки

Исходная строка	Результат предобработки	Выполненные преобразования
Ручка шар. «BIC» син., 0.5мм	ручка шариковая bic синяя 0.5 миллиметр	Нижний регистр; фильтрация пунктуации; раскрытие сокращений; унификация единиц измерения.
Набор мех.кар. «Пифагор» HB 0.7мм с ластиком	пифагор набор механический карандаш пифагор hb 0 7 миллиметр с ластиком	Обогащение строки брендом; нижний регистр; фильтрация спецсимволов; раскрытие сокращений («мех.кар.» $\rightarrow$ «механический карандаш»); унификация единиц измерения.

Выводы по разделу 1

Описаны технологические задачи категоризации и семантического сопоставления потребительских товаров, функционирующие в условиях модели бесконечной полки. Выявлены ключевые системные недостатки ручной обработки входящей номенклатуры, обусловленные высокой вариативностью написания и наличием информационного шума. Приведен критический анализ применения регулярных выражений и статистической меры TF-IDF, доказавший их неэффективность при работе с лексически неоднородными

данными. Обоснован выбор современной контекстной модели ruBERT-tiny2 для извлечения плотных эмбедингов, алгоритма многоклассового градиентного бустинга CatBoost для иерархической классификации и иерархических графов HNSW библиотеки FAISS для высокоскоростного поиска дубликатов в оперативной памяти.

					МИВУ.01.03.02-05.000	ПЗ	Лист
Изм	Лист	№ докум.	Подп.	Дата			24

2. Проектирование системы автоматической категоризации и семантического сопоставления товаров

2.1 Формальная постановка задачи автоматизации категоризации и сопоставления

Для математического описания процесса функционирования системы введем основные множества и операторы. Определим множество описаний товаров $S = \{S_1, S_2, \dots, S_n\}$, где каждый элемент S_i представляет собой неструктурированную текстовую строку на естественном языке, содержащую техническую информацию, бренды и физические характеристики. Также введем конечное множество целевых категорий $C = \{C_1, C_2, \dots, C_m\}$, представляющее собой иерархический справочник товаров. Для перехода от текстовой формы к вычислительной определим пространство эмбедингов $V \subset \mathbb{R}^d$, где размерность $d = 312$ строго соответствует выходному вектору используемой модели `gubert-tiny2`.

Процесс обработки данных в системе описывается через последовательное применение четырех ключевых функций. Функция предобработки текста $T: S \rightarrow S$ выполняет очистку и нормализацию входящей строки, устраняя лексический шум. Функция векторизации $G: T(S) \rightarrow V$ сопоставляет очищенному тексту вектор в пространстве эмбедингов, сохраняя его семантические свойства. На основе полученного вектора функция классификации $f: V \rightarrow C$ определяет наиболее вероятную категорию товара. Наконец, для выявления идентичных позиций введем функцию сопоставления $\text{Sim}: V \times V \rightarrow [0, 1]$, вычисляющую степень смысловой близости между двумя объектами.

Целевой задачей системы является построение функции $F(s)$, возвращающей предсказанный класс товара и найденные дубликаты, с возможностью передачи управления оператору при падении уверенности ниже порога γ :

$$F(s) = \begin{cases} (G(T^*(s)), \text{Sim}(G(T^*(s)), V_{index})), & \text{если } P(c|s) \geq \gamma, \\ \text{Передача оператору, в противном случае} \end{cases}, \quad (1)$$

где $T^*(s)$ – функция предобработки, реализующая информационное обогащение строки при дефиците исходных данных;

$P(c|s)$ – расчетная вероятность правильности классификации товара;

V_{index} – индексная база векторов для поиска дубликатов.

Критерием эффективности системы является максимизация точности категоризации при ограничении на время обработки номенклатурной позиции.

Математическим критерием качества выступает максимизация метрики F_1 -меры при условии, что время обработки одной позиции не превышает установленного порога.

Стандартные подходы осуществляют поиск дубликатов по всей векторной базе в многомерном пространстве $V \subset \mathbb{R}^{312}$, что порождает ложноположительные сопоставления на коротких зашумленных строках [4, 19]. В данной работе предложен метод адаптивного сужения семантического пространства (Adaptive Space Truncation, AST).

Пусть функция классификации $f(v)$ возвращает распределение вероятностей по классам $P = \{p_1, p_2, \dots, p_m\}$. Вводим оператор динамической маски $M(p_i)$, сужающий граф поиска FAISS HNSW только до подмножества векторов, принадлежащих наиболее вероятным категориям:

$$M(p_i) = \begin{cases} 1, & \text{если } p_i \geq \gamma \\ 0, & \text{в противном случае} \end{cases}, \quad (2)$$

где p_i – расчетная вероятность принадлежности товара к i -му классу,

γ – установленный порог уверенности классификатора [21].

Модифицированная функция ближайших соседей Sim^* вычисляется только на фильтрованном множестве векторов $V^* = \{v \in V \mid M(f(v)) = 1\}$:

$$Sim_{AST}(v_{new}, v_{base}) = \cos(v_{new}, v_{base}) \times I(\text{класс}(v_{base}) = \text{класс}(v_{new})), \quad (3)$$

где I – индикаторная функция маскирования разработанного метода адаптивного сужения семантического пространства, принимающая значение, равное 1, если условие в скобках истинно, и 0 – если оно ложно.

Указанная функция активирует маску и разрешает поиск дубликата в графе HNSW FAISS в том случае, если класс товара из базы данных полностью совпадает с классом, который модель CatBoost определила для новой позиции с уверенностью выше порога $\gamma = 0,6$. Это мгновенно отсекает пространство поиска от ложных межклассовых сопоставлений [19, 20].

Математическая задача обучения системы заключается в поиске параметров модели θ , минимизирующих функцию многоклассовой кросс-энтропии на обучающем множестве при соблюдении ограничений на время отклика системы в режиме реального времени:

$$\theta^* = \arg \min_{\theta} \mathcal{L}(f_{\theta}(G(T^*(S))), C), \quad (4)$$

где $t(F(s)) \leq t_{max}$,

f_{θ} – классификатор CatBoost с настраиваемыми параметрами θ ,

$T^*(S)$ – выборка после условной предобработки,

C – истинные метки категорий,

t_{max} – заданный порог времени обработки одной номенклатурной позиции в режиме реального времени.

Функциональные возможности проектируемой системы определяются потребностями участников процесса, выявленными в ходе аналитического этапа. На рисунке 2 представлена диаграмма вариантов использования, которая служит связующим звеном между бизнес-ролями и программными функциями. Прецедент каскадного анализа автоматически включает в себя

извлечение технических характеристик на основе разработанной таблицы правил регулярных выражений.




Рисунок 2 – Диаграмма вариантов использования системы

В контур оператора обработки данных интегрированы процедуры сопоставления дубликатов на базе высокоразмерного поиска в векторном индексе FAISS HNSW и разработанного алгоритма динамического маскирования AST. Данный прецедент расширен условным вектором автоматизированного сбора данных из веб-источников, активируемым автоматически при падении уровня уверенности моделей. Контур специалиста по интеграции обособлен и включает в себя системные прецеденты инициализации легковесного трансформера rubert-tiny2 в режиме заморозки весов и последующий экспорт обученных ансамблей решающих деревьев CatBoost. Предложенная топология полностью устраняет дублирование функций и логически завершает архитектуру системы.

2.2 Математическая модель предобработки текстовых описаний

Процесс подготовки данных в проектируемой системе строится на последовательном применении операторов очистки и нормализации. Математически трансформация ВХН описывается как композиция функций, где

выходное значение каждой предыдущей операции служит аргументом для последующей. Общий вид данной зависимости можно представить как

$$T^*(s) = f_{norm}(f_{abbr}(f_{stop}(f_{tok}(f_{clean}(s_{enriched})))))),$$

где каждая функция отвечает за определенный аспект обработки естественного языка, а $s_{enriched}$ — условно обогащенная текстовая строка.

Первичным этапом является функция базовой очистки $f_{clean}(s)$, которая выполняет нормализацию регистра и удаление шумовых символов. Правило трансформации регистра определяется как отображение каждого символа в его эквивалент в нижнем регистре: $c \rightarrow \text{lower}(c)$. Удаление шума формализуется как фильтрация строки, при которой из последовательности исключаются элементы, входящие в множество неинформативных знаков пунктуации и спецсимволов P : $S_{clean} = \{c \in S \mid c \notin P\}$.

Далее применяется оператор токенизации $f_{tok}(S_{clean})$, который преобразует очищенную строку в последовательность отдельных значимых слов, расположенных в исходном порядке $(w_1, w_2, \dots, w_n)$. В отличие от стандартных методов, алгоритм сохраняет целостность технических артикулов, предотвращая потерю значимых атрибутов при разделении по пробелам. Следующая функция f_{stop} осуществляет фильтрацию чрезмерно зашумляющих символов и артефактов разметки, сохраняя при этом предлоги и союзы, поскольку они формируют синтаксический контекст, необходимый для корректного построения векторов моделью `rubert-tiny2`.

Для восстановления исходного контекста применяется функция дешифровки сокращений f_{abbr} . Она обрабатывает токены w_i на основе словаря соответствий D_{abbr} для раскрытия профессиональной и торговой терминологии в полную форму по правилу:

$$f_{abbr}(w_i) = \begin{cases} W_i, & \text{если } w_i \in D_{abbr} \\ w_i, & \text{в противном случае} \end{cases} \quad (5)$$

где $f_{abbr}(w_i)$ – функция дешифровки текстовых сокращений;

w_i – исходный обрабатываемый токен;

W_i – дешифрованная полная форма токена;

D_{abbr} – словарь нормализованных соответствий профессиональной и торговой терминологии.

Это позволяет преобразовывать технические краткие записи (например, «мех.кар.» в «механический карандаш») в полные наименования.

Завершающим шагом предобработки выступает функция нормализации единиц измерения f_{norm} . Она выполняет унификацию метрических характеристик, приводя вариативные формы записи к единому каноническому идентификатору. Данная нормализация обеспечивает устойчивость системы к различиям в стандартах обозначений и позволяет алгоритму корректно сопоставлять товары при поиске дубликатов. Последующее приведение различных словоформ к единому семантическому виду выполняется автоматически на стороне нейросети с помощью встроенного в rubert-tiny2 токенизатора WordPiece.

2.3 Математическая модель векторизации на основе механизма внимания

Процесс преобразования текстовой последовательности в числовое представление основывается на архитектуре трансформера rubert-tiny2, которая позволяет учитывать контекстные связи между словами. Математическая модель векторизации строится на поэтапном преобразовании входных токенов, начиная с их отображения в пространство начальных эмбеддингов. Для сохранения информации о порядке слов в предложении к полученным векторам применяется механизм позиционного кодирования, после чего данные поступают на слои самовнимания. Основу данного процесса составляет вычисление матриц запросов Q, ключей K и значений V, которые формируются

из входных эмбеддингов путем линейных преобразований с использованием фиксированных предобученных весовых коэффициентов.

Центральным элементом архитектуры является расчет весов внимания, который позволяет модели определять степень влияния каждого токена на итоговый смысл описания товара. Математически механизм внимания выражается формулой (6):

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (6)$$

где Q – матрица запросов;

K – матрица ключей;

V – матрица значений;

d_k – размерность вектора ключей, используемая для масштабирования скалярного произведения и предотвращения доминирования одиночных весов внимания в функции softmax [19].

Схематично процесс трансформации данных можно представить как последовательность логически связанных этапов, начинающихся с формирования входного вектора токенов, дополненного служебными идентификаторами [CLS] в начале и [SEP] в конце последовательности. На следующем этапе к эмбеддингам токенов суммируются позиционные векторы, позволяющие модели учитывать пространственное расположение слов в описании товара. Основной цикл вычислений сосредоточен в слоях энкодера трансформера, где через механизмы многоголового внимания и полносвязные нейронные слои происходит уточнение семантических связей. Результатом прохождения через три последовательных слоя является набор векторов, из которых для дальнейшей классификации извлекается вектор, соответствующий токenu [CLS].

Данный вектор представляет собой концентрированное смысловое описание всей входящей номенклатурной позиции в 312–мерном пространстве.

Использование языковой модели в режиме заморозки весов (без дополнительного дообучения внутренних коэффициентов трансформера) позволяет получить фиксированное признаковое описание, что существенно снижает вычислительные затраты и обеспечивает работу системы в режиме реального времени. Следовательно, подлежащий минимизации вектор параметров θ в целевой функции многоклассовой кросс-энтропии относится исключительно к структуре симметричных решающих деревьев и весовым коэффициентам ансамбля модели градиентного бустинга CatBoost.

2.4 Математическая модель классификации категорий товаров

При проектировании архитектуры классификатора рассматривались две альтернативы: полная перенастройка модели rubert-tiny2 с добавлением классификационного слоя и использование предобученной замороженной модели в связке с внешним алгоритмом градиентного бустинга. Выбор второго варианта как основного обоснован тем, что он требует значительно меньше ресурсов GPU для обучения, обеспечивает лучшую интерпретируемость за счет анализа важности признаков и демонстрирует высокую стабильность при обработке специфической торговой лексики.

Процесс классификации номенклатурных позиций основывается на использовании комбинированного признакового пространства, которое подается на вход модели машинного обучения. Входной вектор классификации формируется путем объединения семантического эмбединга rubert-tiny2, обладающего размерностью 312, и набора дополнительных структурных характеристик, извлекаемых непосредственно из текста номенклатуры. К таким параметрам относится длина строки в символах, общее количество слов, наличие числовых параметров, а также бинарные флаги присутствия известных торговых марок. Добавление подобных свойств важно, так как оно позволяет модели учитывать не только контекстный смысл, но и формальные атрибуты товара, которые часто являются определяющими при выборе категории.

Совокупный признаковый вектор объединяет плотные контекстные эмбединги и эмпирические закономерности структуры торговых наименований, что значительно повышает разделяющую способность классификатора.

Центральным вычислительным элементом системы является модель классификации, построенная на базе алгоритма градиентного бустинга CatBoost. Выбор данной библиотеки обусловлен ее способностью эффективно обрабатывать категориальные признаки без предварительного унитарного кодирования, что снижает риск переобучения и уменьшает объем необходимой предобработки. В основе CatBoost лежит итерационный процесс построения ансамбля симметричных решающих деревьев, где каждое последующее дерево обучается исправлять ошибки предыдущей совокупности моделей. Математически это реализуется через градиентный спуск в функциональном пространстве, где алгоритм ищет такую структуру деревьев, которая максимально приближает предсказанные значения к истинным меткам классов.

Для оптимизации параметров модели в процессе обучения используется функция потерь в виде многоклассовой логистической кросс-энтропии. Данная функция измеряет расхождение между предсказанным вектором вероятностей и фактическим распределением классов, налагая штраф за неуверенность модели в правильном ответе. Математически формулировка функции потерь в данном случае представляется в виде выражения для многоклассовой кросс-энтропии (7),

$$Loss_{type} = -\frac{1}{N} \sum_{item=1}^N \sum_{type=1}^M y_{item,type} \log(p_{item,type}), \quad (7)$$

где N – общее количество товаров в выборке;

M – количество атомарных типов товаров в справочнике;

$y_{item,type}$ – бинарный индикатор (равен 1, если позиция номенклатуры относится к данному типу, и 0 в противном случае);

$p_{item,type}$ – расчетная вероятность, выданная моделью для конкретного типа товара (например, для типа «ЧГ» или «ПВА»).

Финальное предсказание модели формируется на основе формулы ансамблирования, где итоговый результат является суммой предсказаний всех построенных деревьев. Для каждой категории рассчитывается суммарный логистический показатель, который формируется как результат сложения предсказаний всех деревьев в ансамбле.

Последующее преобразование выходных логистических показателей ансамбля деревьев в распределение вероятностей по целевым классам осуществляется с помощью функции Softmax по формуле (8):

$$P(\text{тип}_k | v_{cls}) = \frac{e^{z_k(v_{cls})}}{\sum_{m=1}^M e^{z_m(v_{cls})}}, \quad (8)$$

где v_{cls} – это 312–мерный семантический вектор токена [CLS], полученный от модели rubert–tiny2.

Функция рассчитывает точную вероятность отнесения товара к конкретному типу на основе логистических показателей z , вычисленных ансамблем решающих деревьев CatBoost в рамках M атомарных классов.

В разрабатываемой системе классификация выполняется иерархически: отдельные модели CatBoost обучаются для предсказания категории, сегмента и типа товара. Приведённая математическая модель (формулы (7) и (8)) описывает обучение и предсказание для уровня типов; для уровней категорий и сегментов она применяется аналогично с соответствующим количеством классов.

Процесс ранжирования результатов заключается в упорядочивании всех возможных категорий по убыванию полученных вероятностей. Выбор целевого узла в справочнике осуществляется путем нахождения аргумента максимума вектора полученных вероятностей, что соответствует категории с наибольшим расчетным значением вероятности.

2.5 Математическая модель семантического сопоставления

Задача семантического сопоставления в рамках проектируемой системы заключается в поиске пар объектов, которые с высокой степенью вероятности описывают один и тот же товар в реальном мире. Математически данная задача формулируется как нахождение подмножества пар векторов в пространстве эмбедингов, семантическое сходство между которыми максимально. В отличие от задачи классификации, где целью является отнесение объекта к группе, сопоставление направлено на установление точечных связей между элементами массива данных для устранения дублирования в каталоге.

Для количественной оценки смысловой близости двух номенклатурных позиций используется метрика косинусного сходства. Данный выбор обусловлен тем, что в высокоразмерных пространствах признаков направление вектора несет больше информации о семантике текста, чем его абсолютная длина. Косинусное сходство между векторами v_{new} и v_{base} вычисляется как отношение их скалярного произведения к произведению их евклидовых норм, что представляется в виде формулы (9),

$$Sim_{AST}(v_{new}, v_{base}) = \frac{v_{new} \cdot v_{base}}{\|v_{new}\| \|v_{base}\|} \times I(\text{класс}(v_{base}) = \text{класс}(v_{new})), \quad (9)$$

где $\cdot$ означает скалярное произведение векторов, $\|\cdot\|$ их евклидову норму. Покомпонентно в 312–мерном пространстве эмбедингов числитель формулы 9 раскрывается как сумма произведений координат $\sum_{r=1}^{312} v_{new,r}$, а знаменатель как произведение квадратных корней из суммы квадратов координат каждого вектора. Символ I обозначает индикаторную функцию, которая равна 1, если предсказанный класс нового товара совпадает с классом эталона из базы данных, и 0 в противном случае, при этом итоговый результат вычислений варьируется в диапазоне $[0; 1]$.

Принятие решения о признании двух позиций дубликатами основывается на методе пороговой фильтрации. Система фиксирует равенство объектов в том случае, если вычисленное значение косинусного сходства превышает установленный порог принятия решения γ . Данный параметр определяется эмпирическим путем в ходе калибровки модели на контрольной выборке, что позволяет достичь оптимального баланса между полнотой обнаружения дубликатов и точностью сопоставления, исключая ложные срабатывания на похожих, но не идентичных товарах [20, 21].

С учетом необходимости обработки массивов данных объемом в миллионы записей, линейная сложность поиска $O(N)$ является неприемлемой для систем реального времени. С целью сокращения вычислительной трудоемкости сопоставления в математическую модель интегрирован алгоритм построения графов приблизительных ближайших соседей HNSW (Hierarchical Navigable Small World), реализованный с использованием библиотеки FAISS.

Использование иерархических графов позволяет организовать пространство эмбедингов таким образом, чтобы поиск наиболее похожих векторов осуществлялся за логарифмическое время относительно общего объема базы данных. Применение подобных структур данных в сочетании с индексацией обеспечивает функционирование системы в режиме реального времени, позволяя мгновенно идентифицировать аналогичные позиции при добавлении новых товаров в базу данных.

2.6 Обоснование и описание архитектуры системы

Проектируемая архитектура ориентирована на создание универсального инструмента автоматизации рабочего места оператора и представляет собой программный комплекс с модульной структурой. Система обеспечивает сквозной цикл обработки данных от момента загрузки внешних файлов до получения верифицированного массива данных, содержащего результаты автоматической категоризации и семантического сопоставления номенклатурных позиций.

					МИВУ.01.03.02-05.000	ПЗ	Лист
Изм	Лист	№ докум.	Подп.	Дата			36

Ключевым отличием разработанной архитектуры является организация сквозного высокоскоростного конвейера обработки данных без использования внешних реляционных систем управления базами данных, что позволяет минимизировать временные задержки при обработке больших массивов номенклатур.

В рамках данного конвейера дистиллированный трансформер rubert-tiny2 преобразует очищенные текстовые строки в фиксированные 312-мерные семантические векторы, которые последовательно передаются в иерархический классификационный каскад моделей CatBoost. Пошаговое выполнение инференса на уровне категорий, сегментов и конкретных типов товаров подготавливает точные координатные метки для работы модуля автоматического извлечения физических атрибутов.

Движок семантического сопоставления осуществляет приближенный поиск ближайших соседей на графах HNSW непосредственно в оперативной памяти с использованием библиотеки FAISS и наложением разработанной динамической маски AST. Локальный импорт и экспорт структурированных каталогов производятся напрямую через файлы табличных процессоров, обеспечивая автономность интеллектуального ядра.

Структурная организация программного комплекса представлена на диаграмме компонентов на рисунке 3.




Рисунок 3 – Диаграмма компонентов системы

Взаимодействие модулей в рамках серверной части осуществляется посредством прямого вызова функций с передачей данных в форматах структурированных массивов и тензоров PyTorch. Ввиду ориентации разработанной системы на потоковую обработку информации в режиме реального времени, в архитектуре не предусматривается использование внешних реляционных СУБД, что позволяет исключить накладные расходы на дисковые транзакции. Интеграция с векторным движком сопоставления аналогов реализована через специализированный Python–интерфейс библиотеки FAISS в оперативной памяти. Концептуальная модель логической структуры данных, определяющая порядок размещения исходных и обогащаемых атрибутов номенклатурных позиций в файлах локального табличного процессора совместно со структурой хранения высокоразмерных векторов в оперативной памяти, представлена на рисунке 4.




Рисунок 4 – Концептуальная модель данных и структура хранения

Динамика сквозных вычислительных процессов при автоматизированной обработке входящего номенклатурного файла и логика обработки исключительных ситуаций наглядно визуализируются на диаграмме последовательности на рисунке 5. Данная схема демонстрирует полный путь прохождения информационных потоков от момента инициализации

пользователем процедуры импорта исходного документа до получения итогового обогащенного отчета со всеми этапами интеллектуального анализа.




Рисунок 5 – Диаграмма последовательности обработки данных

Представленный на диаграмме последовательности сценарий является основным вычислительным процессом функционирования программного комплекса. При обнаружении неполноты данных или падении расчетной вероятности каскада моделей CatBoost ниже установленного порога уверенности в 0,6, управление передается первому защитному контуру. Система

в автоматическом режиме выполняет условный синтаксический веб-анализ карточки товара по URL-ссылке для обогащения исходной строки. Если после повторного инференса уровень уверенности классификатора по-прежнему не достигает отметки 0,7, активируется процедура изоляции данных. В этом случае неопределенная номенклатурная позиция перенаправляется в специализированную буферную очередь для ручной верификации и ручного обогащения оператором мастер-данных, что гарантирует абсолютную чистоту итогового товарного каталога.




Рисунок 6 – Диаграмма деятельности процесса обработки товарной записи

Для детализации процесса обработки данных и визуализации логических ветвлений разработана диаграмма деятельности, представленная на рисунке 6. В отличие от статического описания формул, диаграмма наглядно демонстрирует

сценарии поведения системы в зависимости от качества входного контекста. обнаружении дефицита информации или падении уверенности каскада ниже порога $\gamma = 0,6$, алгоритм активирует контур условного синтаксического веб-анализа по URL-ссылке карточки товара. В случае, если после автоматического обогащения текста итоговая уверенность не достигает отметки 0,7, позиция изолируется и перенаправляется в буферную очередь для ручной разметки оператором, что гарантирует чистоту итогового каталога.

Физическое размещение программных компонентов, локальных слоев хранения и распределенных вычислительных модулей на базе CPU и GPU отражено на диаграмме развертывания на рисунке 7. В отличие от классических клиент-серверных архитектур с избыточными дисковыми транзакциями, спроектированная топология развертывания ориентирована на высокоскоростное выполнение вычислений непосредственно в оперативной памяти в рамках единой виртуальной среды. Это исключает накладные расходы на обращение к внешним дисковым подсистемам и обеспечивает максимальную пропускную способность разработанного комплекса при пакетной обработке номенклатурных файлов.




Рисунок 7 – Диаграмма развертывания компонентов системы

2.7 Разработка прототипа системы

Программная реализация выполнена на языке Python 3.10. Для векторизации текстов моделью rubert-tiny2 применены библиотеки PyTorch и Transformers. Построение трехуровневого каскада классификации реализовано средствами библиотеки CatBoost, а высокопроизводительный поиск дубликатов в оперативной памяти функционалом библиотеки FAISS с наложением разработанной динамической маски AST.

Первичным этапом конвейера является функция лингвистической предобработки, реализующая очистку от графического шума и конкатенацию признаков для формирования устойчивого контекста:

```
def fix_and_clean_df(df_target):
    df_res = df_target.copy()

    df_res['brand'] = df_res['brand'].fillna("").astype(str).strip()
    df_res['name'] = df_res['name'].fillna("").astype(str).strip()

    def advanced_preprocess(text):
        text = text.lower()
        text = re.sub(r'(\d+)\s*(мм|мл|гр|л|шт|уп|л|мл|г)', r'\1\2', text)
        text = re.sub(r'^a-za-я0-9.\s', '', text)
        return " ".join(text.split())

    df_res['combined_text'] = df_res['brand'] + " " + df_res['name']
    df_res['clean_text'] = df_res['combined_text'].apply(advanced_preprocess)
    return df_res
```

Второй ключевой компонент – процедура автоматической балансировки классов методом oversampling. Она устраняет критический дисбаланс (перекос обучающей выборки в сторону канцелярии) путем искусственного дублирования редких бритвенных позиций до размера мажоритарного класса:

```
def balance_and_vectorize(df_train, df_val, vectorizer):
    processed_train = fix_and_clean_df(df_train)
    processed_val = fix_and_clean_df(df_val)

    max_class_size = processed_train['Категория'].value_counts().max()
    balanced_train = []

    for category_name, group in processed_train.groupby('Категория'):
```

```

if len(group) < max_class_size:
    over_sampled_group = resample(group, replace=True,
                                   n_samples=max_class_size,
                                   random_state=42)
    balanced_train.append(over_sampled_group)
else:
    balanced_train.append(group)

train_balanced = pd.concat(balanced_train).sample(frac=1,
random_state=42).reset_index(drop=True)

X_train_raw =
np.array(vectorizer.get_embeddings(train_balanced['clean_text'].tolist())).astype('float32')
X_val_emb =
np.array(vectorizer.get_embeddings(processed_val['clean_text'].tolist())).astype('float32')

is_duplicate = train_balanced.duplicated(subset=['clean_text'], keep='first').values
np.random.seed(42)
noise = np.random.normal(0, 1e-4, X_train_raw.shape).astype('float32')
X_train_emb = np.where(is_duplicate[:, None], X_train_raw + noise, X_train_raw)

return X_train_emb, X_val_emb, train_balanced, processed_val

```

Необходимо отметить, что применение метода искусственного дублирования миноритарных классов традиционно сопряжено с риском переобучения модели на повторяющихся примерах. Для нивелирования данного эффекта и обеспечения высокой обобщающей способности в разработанном программном комплексе реализован комплекс взаимосвязанных компенсирующих механизмов.

Во-первых, в системе задействован принцип заморозки весов экстрактора признаков, вследствие чего обучение каскада классификаторов CatBoost происходит не на исходных текстовых токенах, а на фиксированных векторных представлениях предобученной модели rubert-tiny2. Поскольку веса трансформера неизменяемы, модель физически лишена возможности переобучаться на синтаксическом шуме или конкретных буквенных сочетаниях отдельных номенклатурных строк.

Во-вторых, математический аппарат классификатора стабилизируется посредством встроенной L2-регуляризации, где в конфигурации гиперпараметров градиентного бустинга жестко задан штрафной коэффициент `l2_leaf_reg=10`, эффективно ограничивающий величину весов в листьях

решающих деревьев и подавляющий избыточную подгонку под дублирующиеся векторы.

В–третьих, для устранения эффекта идентичности признаков размноженных миноритарных классов, в систему интегрирован модуль стохастической регуляризации эмбедингов. Он накладывает на каждый дублированный вектор контролируемый псевдослучайный шум, распределенный по нормальному закону Гаусса с математическим ожиданием $\mu=0$ и дисперсией $\sigma^2=10^{-4}$. Это заставляет алгоритм бустинга формировать устойчивые разделяющие гиперплоскости вокруг кластеров потребительских товаров, а не запоминать изолированные точки пространства.

В–четвертых, сквозной контроль переобучения осуществляется по независимой валидационной выборке с помощью алгоритма ранней остановки, который принудительно прерывает процесс наращивания ансамбля деревьев, если в течение 150 итераций ошибка многоклассовой кросс–энтропии на валидационном множестве `processed_val` (которое не подвергалось дублированию и содержит только реальные уникальные рыночные данные) перестает снижаться.

Последующий процесс обучения инициализирует параметры ансамблей решающих деревьев `CatBoostClassifier`. Для минимизации многоклассовой кросс-энтропии, интеграции комбинированного пространства признаков и защиты от эффекта переобучения применяется аппаратное ускорение на графических процессорах и алгоритм ранней остановки по валидационному множеству:

```
cb_ultra_params = {  
    'iterations': 3000,  
    'learning_rate': 0.03,  
    'depth': 6,  
    'l2_leaf_reg': 10,  
    'random_strength': 2,  
    'bootstrap_type': 'Bernoulli',  
    'subsample': 0.8,  
    'task_type': 'GPU',  
    'early_stopping_rounds': 150,  
    'verbose': False
```

```

}
model_cat = CatBoostClassifier(**cb_ultra_params).fit(
    X_train_final, train_balanced['Категория'],
    eval_set=(X_val_final, processed_val['Категория'])
)
model_cat.save_model('category_model.bin')

X_train_final['Parent_Category'] = train_balanced['Категория'].astype(str)
X_val_final['Parent_Category'] = processed_val['Категория'].astype(str)

train_pool_seg = Pool(X_train_final, train_balanced['Сегмент'], cat_features=['Parent_Category'])
val_pool_seg = Pool(X_val_final, processed_val['Сегмент'], cat_features=['Parent_Category'])

model_seg = CatBoostClassifier(**cb_ultra_params).fit(train_pool_seg, eval_set=val_pool_seg)
model_seg.save_model('segment_model.bin')

```

Разработанная архитектура обеспечивает изоляцию уровней классификации. При изменении внутренней структуры конкретной продуктовой линейки обучению подвергается только соответствующая изолированная модель каскада, не затрагивая остальные компоненты распределенной системы справочников номенклатуры.

Выводы по разделу 2

На этапе проектирования системы и её математического описания сформирован полный комплекс алгоритмического обеспечения. Формализована математическая постановка задачи сквозного семантического анализа на основе четырех последовательных операторов. Разработана математическая модель предварительной обработки текстовых описаний, представляющая собой многоэтапный конвейер детерминированных функций очистки, токенизации, раскрытия сокращений и нормализации единиц измерения. Описана математическая модель векторизации на основе фиксированных предобученных коэффициентов механизма внимания трансформера rubert-tiny. Построена математическая модель трехуровневой каскадной классификации CatBoost, минимизирующая многоклассовую кросс-энтропию. Спроектирован авторский метод адаптивного сужения семантического пространства AST с динамическим

маскированием иерархического графа FAISS HNSW, исключая ложноположительные межклассовые сопоставления.

3 Экспериментальное исследование

3.1 Подготовка набора данных и описание экспериментальной среды

Экспериментальная часть работы направлена на проверку выдвинутых гипотез о преимуществе выбранного технологического стека. Для того чтобы результаты тестирования системы были достоверными, необходимо детально проработать этап подготовки данных, так как качество обучения моделей напрямую зависит от чистоты и структуры обучающей выборки. Процесс подготовки разделен на анализ исходных структур, многоэтапную очистку и формирование выборок для контроля качества обучения.

Для обеспечения высокой обобщающей способности проектируемой трехуровневой системы семантического анализа иерархического справочника (Категория → Сегмент → Тип) критически важным этапом является определение оптимального объема обучающего множества [21, 22].

Применение ограниченного объема данных приведет к системным ошибкам из-за неравномерного распределения строк по уровням классификации. Верхние уровни каскада CatBoost при дисбалансе классов будут смещать предсказания в пользу наиболее крупных, часто встречающихся групп товаров. В то же время нижний уровень архитектуры, представленный моделью классификации типов на базе CatBoost, столкнется с критическим недообучением из-за нехватки репрезентативных примеров для редких атомарных позиций каталога.

Для преодоления указанных ограничений был применен метод жесткой комбинаторной балансировки и аугментации миноритарных классов на верхнем уровне иерархии справочника. Алгоритм определяет мощность мажоритарного класса выборки $N_{\max}$ (категория «Канцелярские товары») и осуществляет дублирование объектов миноритарного класса (категория «Бритвенные принадлежности») до достижения эквивалентной плотности распределения. Мощность итогового сбалансированного множества N_{balanced} формализуется выражением:

$$N_{\text{balanced}} = 2 \times N_{\text{max}}.$$

Для проведения экспериментальных исследований был сформирован исходный набор данных, содержащий структурированную информацию о потребительских товарах. В структуре выборки выделено $M_{\text{cat}} = 2$ категории верхнего уровня, представленные классами «Канцелярские товары» и «Бритвенные принадлежности». На среднем уровне иерархии сформировано 12 сегментов, а на нижнем атомарном уровне справочник содержит 37 типов товаров, зафиксированных в структуре иерархии.

Для предотвращения локального недообучения и переобучения на уровне укрупненных классов объем данных миноритарного класса был полностью сбалансирован на верхнем уровне иерархии методом случайного избыточного дублирования. В результате выравнивания общая мощность выборки по категории «Бритвенные принадлежности» была доведена до объема мажоритарного класса. При этом на вложенных уровнях классификации (сегменты и атомарные типы) сохраняется естественный структурный дисбаланс классов, обусловленный разным количеством исходных рыночных позиций в укрупненных группах, что накладывает жесткие требования на выбор метрик валидации.

Наиболее многочисленной категорией является «Канцелярские товары», объединяющая 31 тип изделий и содержащая в сумме 83731 запись, что составляет 83,76% от общего объема выборки. Самой малочисленной категорией выступает группа «Бритвенные принадлежности», включающая 6 типов и содержащая 16229 строк, или 16,24% от массива данных. Соответственно, коэффициент дисбаланса классов на верхнем уровне как соотношение большинства к меньшинству составляет 5,16 к 1, что критично для выбора итоговых метрик и заставляет использовать инвариантную к объемам метрику macro-F1 совместно с weighted-F1. Анализ геометрических характеристик текстовых строк показал, что средняя длина описания составляет 42 символа, минимальная – 14 символов, а максимальная – 112 символов.

Данное распределение позволило математически обосновать и зафиксировать параметр максимальной длины последовательности $\text{max_length} = 128$ токенов для модели `rubert-tiny2`, что полностью перекрывает плотность распределения длин и оптимизирует затраты памяти графического процессора.

Таблица 4 – Распределение номенклатурных записей по уровням классификации

Категория	Сегмент	Количество типов, классов	Количество записей, шт.	Доля от общей выборки, %
Бритвенные принадлежности	Системы	2	5402	5,4%
	Одноразовые	1	2701	2,7%
	Двусторонние лезвия	1	2701	2,7%
Канцелярские принадлежности	Ручки	5	13505	13,51%
	Маркеры	7	18907	18,91%
	Карандаши	2	5402	5,4%
	Цветные карандаши	1	2701	2,7%
	Фломастеры	1	2701	2,7%
	Клей	5	13505	13,51%
	Ластики	1	2701	2,7%
	Корректирующие инструменты	3	8103	8,11%
	Мелки	2	5402	5,4%
	Прочее	6	16206	16,21%
Итого (N)	13	37	99960	100%

Для предотвращения локального недообучения и смещения разделяющих поверхностей моделей многоклассовой классификации на нижнем шаге иерархии, объем данных миноритарного класса верхнего уровня («Бритвенные принадлежности») был искусственно увеличен методом случайного избыточного дублирования до объема мажоритарного класса. Применение данного подхода гарантирует, что алгоритм построения ансамблей решающих деревьев CatBoost получит репрезентативный объем статистической информации по укрупненным целевым ветвям справочника. Это исключает смещение вычисляемого градиента функции потерь в сторону более популярных потребительских товаров и позволяет модели одинаково точно формировать решающие границы в комбинированном признаковом

пространстве как для базовых офисных принадлежностей, так и для специфических бритвенных систем, сохраняя при этом естественные пропорции распределения вложенных атомарных типов.

При этом на промежуточных уровнях классификации возникает естественный структурный дисбаланс, точно воспроизводящий топологию реальных основных данных. Наиболее масштабным выступает сегмент маркеров (7 типов, 18907 записей, 18,91% от выборки). Сегменты ручек и клеев включают по 5 типов (по 13505 записей, 13,51% каждого). Миноритарные однокомпонентные сегменты (цветные карандаши, ластики, фломастеры) содержат по 2701 строке (по 2,70%). Наличие данного структурного дисбаланса позволяет комплексно проверить устойчивость разработанной каскадной архитектуры к неравномерной плотности распределения векторов. Кроме того, массив такого размера позволяет внедрить до 60% комбинаторных перестановок слов, до 15% симулированных орфографических опечаток и синонимизацию единиц измерения без риска вырождения векторного пространства семантических признаков, что обеспечивает инвариантность к зашумлению.

С точки зрения вычислительного баланса суммарный объем извлекаемой матрицы плотных признаков составляет 31187520 элементов (99960 строк на 312 координат). Генерация векторов через трансформер на графическом процессоре NVIDIA T4 занимает около 2 минут времени и требует порядка 4,5 ГБ оперативной памяти.

Таким образом, сформированная выборка служит теоретически обоснованным базисом, исключаяющим смещение градиента и обеспечивающим высокую обобщающую способность системы на реальных потоках входящей номенклатуры.

При проектировании архитектуры экспериментального исследования масштабированного массива данных возникает необходимость строгого математического обоснования разделения выборки на подмножества и защиты моделей от скрытых деструктивных эффектов, способных исказить итоговые

метрики качества. В рамках данной работы были детально проработаны и формализованы три ключевых методологических вопроса

Разделение исходного набора данных на обучающее, валидационное и тестовое множества выполнено в пропорции 80%, 10% и 10% с обязательным применением метода стратификации. Стратифицированное расщепление гарантирует строгое сохранение пропорций всех тридцати семи атомарных типов товаров и общего коэффициента дисбаланса в каждом из сформированных подмножеств. В результате разбиения обучающая выборка составила 79968 записей, валидационная – 9996 записей, тестовая – 9996 строк. Обучающий массив используется для настройки внутренних параметров каскада моделей CatBoost, а валидационное множество в качестве независимого критерия для реализации механизма ранней остановки и предотвращения переобучения.

Критической ошибкой при искусственном расширении текстов является «утечка данных». Если масштабировать исходный массив путем синонимизации, а затем применить случайное разделение, то лексические клоны одних и тех же позиций гарантированно попадут одновременно и в обучающее, и в тестовое подмножества. Это нарушает допущение о независимости выборок. Ансамбль деревьев CatBoost за счет высокой емкости мгновенно переобучится на синтаксических маркерах знакомых позиций, демонстрируя ложную точность до 99,9%. При столкновении с реальным потоком неизвестной номенклатуры точность такой системы рухнет.

Для полного купирования эффекта утечки данных в работе реализован алгоритм изолированного объектно–ориентированного расщепления выборки. На первом этапе верифицированный набор данных разделяется на подмножества до запуска генераторов шума. Процедура комбинаторной аугментации применяется исключительно к изолированной обучающей выборке для увеличения ее объема. Тестовый и валидационный массивы формируются обособленно на основе реальных исходных строк номенклатуры, полученных из открытых API маркетплейсов.

Это гарантирует математическую строгость эксперимента: модели обучаются на искусственно расширенной зашумленной среде, имитирующей человеческий фактор, но тестируются на независимых объектах. При проектировании было обосновано подмножество контроля. Искусственное зашумление тестовой выборки алгоритмами синтетического дополнения признано нецелесообразным, поскольку тест должен отражать естественное распределение и плотность реального потока входящих позиций без внесения математических искажений со стороны генераторов шума.

Искусственное зашумление тестовых данных исказило бы распределение признаков, превратив оценку модели в проверку её способности распознавать конкретный алгоритмический шум, а не семантику слов. Поскольку целевой задачей системы является сопоставление зашумленной входящей номенклатуры с эталонным справочником, обученный каскад должен корректно отображать искаженный текст в целевой класс. Тестирование на независимых исходных данных позволяет объективно оценить обобщающую способность системы.

Помимо специфических характеристик, для каждой позиции заполняются универсальные поля: производитель, бренд и саббренд. Сложность извлечения данных заключается в их вариативности и частых сокращениях. Бренд может быть записан смешанным алфавитом, а саббренд отсутствовать в явном виде. В таблице 5 представлен фрагмент регулярных выражений, использованный для конфигурирования модуля автоматического извлечения атрибутов.

Таблица 5 – Правила заполнения атрибутов для различных сегментов товаров

Характеристика	Варианты значений	Условие заполнения сегмент/категория
Пол	Жен.; муж.	Только для категории бритвы
Характеристика	Варианты значений	Условие заполнения сегмент/категория
Количество лезвий	Числовое (1–100)	Только для категории бритвы
Характеристика	Варианты значений	Условие заполнения сегмент/категория
Объем/вес	Число в граммах	Сегмент клей и корректирующие

		инструменты
Механизм	Авт.; не авт.	Только для сегмента ручки
Цвет	В соответствии с указанным в ВХН	Только для сегмента ручки и маркеры
Толщина карандаша	НВ; Другие; Набор	Только для сегмента карандаши
Толщина письма	Числовое (1–100)	Сегменты ручки и маркеры

Продолжение таблицы 5

Характеристика	Варианты значений	Условие заполнения сегмент/категория
Формат упаковки	Блистер; карт.уп.; п.; метал.уп.; текст.уп.	Канцелярские принадлежности
Доп. свойства	С грипом; с ластиком; без грипа; без ластика; пулев.; круг.; игольч.	Ручки, карандаши, маркеры

3.2 Методика проведения экспериментов

В рамках экспериментальной верификации разработанного программного комплекса проверяются три ключевые гипотезы.

Первое предположение заключается в том, что использование контекстных эмбеддингов предобученного трансформера rubert–tiny2 в качестве признакового описания для градиентного бустинга CatBoost обеспечивает более высокую точность многоклассовой классификации текстовых номенклатур по сравнению с классическими статистическими методами векторизации.

Вторая гипотеза утверждает, что предложенный метод адаптивного сужения семантического пространства существенно сокращает временную сложность поиска дубликатов на графах HNSW без статистически значимого падения полноты сопоставления.

Третье предположение состоит в том, что проведение процедур стратификации на этапе разделения выборок полностью купирует риски смещения градиента на миноритарных классах и обеспечивает устойчивость каскада моделей.

Для комплексной оценки качества каскадной классификации используются метрики macro–F1 и weighted–F1. Метрика macro–F1 рассчитывается как среднее арифметическое значение F1–меры по всем

целевым классам. Это позволяет объективно оценить качество распознавания на нижнем шаге иерархии независимо от структурного дисбаланса, присутствующего на уровнях категорий и сегментов. Метрика weighted-F1 учитывает объемы укрупненных групп, отражая средневзвешенную точность системы на потоке номенклатуры.

Эффективность семантического сопоставления и поиска аналогов в векторном индексе FAISS оценивается с помощью метрик Precision@k, Recall@k и их гармонического среднего F1@k. Показатель Precision@k определяет долю истинных дубликатов среди k первых возвращенных результатов поиска. Метрика Recall@k фиксирует долю найденных истинных дубликатов от их общего числа в базе данных, измеряя полноту охвата системы. Интегральный показатель F1@k рассчитывается как гармоническое среднее между точностью и полнотой по k верхним позициям, обеспечивая сбалансированную оценку качества ранжирования.

Для векторизации текстов использовалась модель rubert-tiny2 в режиме замороженных весов, генерирующая плотные признаки размерностью 312. Оптимизация гиперпараметров ансамблей CatBoost (глубины деревьев depth, скорости обучения learning_rate и коэффициента регуляризации l2_leaf_reg) осуществлялась методом рандомизированного поиска со встроенной кросс-валидацией. Контроль переобучения выполнялся на валидационном подмножестве с минимизацией функции многоклассовой кросс-энтропии.

Для оценки качества каскадной классификации и векторного поиска в рамках экспериментального исследования вычисляются метрики:

– Усредненная по классам F1-мера для оценки устойчивости каскада к дисбалансу на верхних уровнях:

$$macro-F1 = \frac{1}{M} \sum_{i=1}^M \frac{2 \cdot Precision_i \cdot Recall_i}{Precision_i + Recall_i}, \quad (10)$$

– Средневзвешенная F1–мера, учитывающая весовые доли w_i объема номенклатурных сегментов в выборке:

$$weighted-F1 = \sum_{i=1}^M w_i \cdot F1_i, \text{ где } w_i = \frac{N_i}{N} \quad (11)$$

– Точность векторного поиска дубликатов на уровне k верхних позиций в индексе FAISS HNSW:

$$Precision@k = \frac{1}{k} \sum_{j=1}^k I(colocated_j), \quad (12)$$

– Полнота векторного поиска аналогов среди k ближайших соседей в графе:

$$Recall@k = \frac{\text{Истинные дубликаты в топ-}k}{\text{Общее число дубликатов}} \quad (13)$$

Интегральный показатель качества ранжирования $F1@k$ рассчитывается как стандартное гармоническое среднее между вычисленными значениями $Precision@k$ и $Recall@k$.

Оптимизация параметров ансамблей CatBoost выполнялась на валидационном подмножестве объемом 9996 записей с помощью метода рандомизированного поиска. В ходе процедур автоматического подбора были определены следующие оптимальные параметры, минимизирующие многоклассовую кросс-энтропию: скорость обучения $learning_rate = 0,03$, глубина деревьев $depth = 6$, количество итераций $iterations = 3000$ и регуляризационный параметр $l2_leaf_reg = 10$.

Обоснование максимальной длины последовательности для трансформера rubert–tiny2 основано на анализе распределения длин строк (максимум 112 символов). Значение параметра зафиксировано на уровне $max_length = 128$ токенов, что полностью исключает усечение длинных номенклатур и оптимизирует затраты памяти GPU. Настройка параметров индексирования

графа HNSW в библиотеке FAISS выполнялась экспериментально на валидационной выборке. Количество связей узла зафиксировано на уровне $M=16$, глубина оценки при конструировании составила $efConstruction=64$. В режиме реального времени при поиске ближайших соседей параметр контроля точности был установлен как $efSearch=32$. Это позволило полностью уложиться в аппаратные лимиты серверной инфраструктуры.

3.3 Результаты экспериментов и их анализ

Результаты экспериментального исследования подтвердили эффективность предложенной каскадной архитектуры на базе эмбедингов `rubert-tiny2` и градиентного бустинга `CatBoost`. Тестирование обученных моделей выполнялось на подмножестве объемом 9996 номенклатурных позиций.

При оценке качества классификации верхнего уровня (категории) показатель сбалансированной точности и метрика `macro-F1` составили 0,99. На среднем уровне иерархии (сегменты) модель продемонстрировала общую точность 0,99 на 13 целевых классах. На нижнем шаге классификации (атомарные типы) значение `macro-F1` зафиксировано на отметке 0,985 для 37 классов. Полученные результаты подтверждают способность разработанного каскада формировать устойчивые решающие границы для близких лексических позиций.

Таблица 6 – Динамика обучения классификатора нижнего уровня

Номер итерации	Значение функции потерь на обучении	Значение функции потерь на валидации	Затраченное время
0	3,2590	3,4881	254 мс
400	0,095	0,1567	1 мин
800	0,05212	0,0893	1 мин 53 с
1200	0,0401	0,0704	2 мин 42 с

1600	0,0298	0,0552	3 мин 33 с
2000	0,0235	0,046	4 мин 24 с
2400	0,0195	0,0405	5 мин 14 с
2800	0,0163	0,0365	6 мин 8 с

Анализ динамики обучения демонстрирует монотонное убывание функции потерь на обоих подмножествах, что подтверждает корректность регуляризации и отсутствие переобучения. Сводные показатели точности трехуровневого каскада на тестовой выборке представлены в таблице 7.

Таблица 7 – Результаты обучения и точности моделей иерархического каскада

Уровень классификации	Итоговое число итераций	Значение функции потерь (Validation)	Точность (Accuracy)	Усредненная F1–мера (Macro Avg)
Верхний (категория)	2997	0,1176	0,991	0,991
Средний (сегмент)	3000	0,0163	0,994	0,994
Нижний (тип товара)	3000	0,0347	0,985	0,985

Анализ результатов подтверждает высокое качество классификации на всех уровнях иерархии справочника. Максимальное значение точности зафиксировано на промежуточном уровне сегментов и составило 0,994, а на нижнем шаге определения атомарных типов метрика macro-F1 достигла отметки 0,985. Каскад моделей продемонстрировал устойчивость к синтаксическому шуму, успешно определив классы для строк с вариативностью регистра при ручном вводе и ошибками пунктуации. Достигнутая точность формирует надежный базис для последующего семантического поиска дубликатов.

Экспериментальная проверка метода адаптивного сужения семантического пространства подтвердила его эффективность. Метрика точности Precision@5 составила 0,9411, что указывает на высокую долю истинных дубликатов среди пяти первых возвращенных кандидатов. Показатель полноты Recall@5 достиг значения 0,9803, подтверждая минимальный риск

пропуска целевых аналогов. Интегральная метрика F1@k зафиксирована на отметке 0,9603.

Сравнительный анализ разработанного каскада со статистической векторизацией TF-IDF и логистической регрессией продемонстрировал прирост точности классификации на 24,36%, что обусловлено неспособностью классических методов сопоставлять лексически разнородные номенклатуры. Внедрение метода динамического маскирования AST ограничило пространство поиска релевантными ветвями справочника, что сократило среднее время выполнения векторного сопоставления одной позиции в индексе FAISS до 0,58 мс. С учетом этапов предобработки, векторизации и каскадного инференса суммарное время сквозного анализа одной строки составило 6,2 мс, что обеспечивает функционирование программного комплекса в режиме реального времени.

Итоговые показатели эффективности разработанных модулей классификации товарных категорий и семантического сопоставления номенклатурных позиций представлены на рисунке 8.

Результаты семантического поиска с методом AST:
Точность ранжирования: 0.9411
Полнота сопоставления: 0.9803
Интегральный показатель качества: 0.9603
Среднее время обработки одного документа: 0.58 мс




Рисунок 8 – Итоговые показатели эффективности разработанной системы

Для верификации гипотезы о преимуществе разработанного стека проведено его сравнительное тестирование со статистической мерой TF-IDF в связке с логистической регрессией. Эксперимент показал, что базовый подход демонстрирует точность macro-F1 на уровне 0,7214. Основной причиной падения качества базового метода является высокая зашумленность входящей номенклатуры. Поскольку метод TF-IDF игнорирует семантический контекст, он неспособен сопоставлять лексически разнородные позиции. Интеграция модели rubert-tiny2 позволила преодолеть данное ограничение, обеспечив прирост точности классификации на 24,36% за счет извлечения инвариантных к шуму плотных векторов.

Важной частью экспериментального исследования выступила верификация разработанного метода адаптивного сужения семантического пространства, предназначенного для оптимизации поиска в векторной базе FAISS. В ходе тестирования проводилось сравнение времени отклика и точности ранжирования при сквозном поиске по всему графу HNSW и при поиске с использованием динамической маски классификатора. Применение сквозного поиска по всей базе без предварительной фильтрации привело к возникновению ложноположительных семантических сопоставлений, когда из-за краткости и специфичности текстовых описаний система ошибочно сопоставляла канцелярские ручки со сменными бритвенными кассетами из-за схожих артикулов. Внедрение метода динамического маскирования AST ограничило область поиска в FAISS релевантными ветвями справочника, полностью устранив межклассовые ложные срабатывания.

Финальный этап экспериментов посвящен оценке влияния разработанного конвейера предобработки на стабильность системы. Экспериментально доказано, что сохранение исходных словоформ в сочетании с унификацией единиц измерения обеспечивает оптимальный размер словаря токенов WordPiece. При этом отказ от нормализации метрических параметров снижает итоговую точность классификации CatBoost на 8,43%. Применение алгоритма изолированного расщепления выборки до этапа генерации шума полностью исключило эффект утечки данных, обеспечив совпадение метрик на

валидационном и тестовом множествах с погрешностью в пределах 0,5%. Эксперименты подтвердили теоретическую обоснованность проектных решений, доказав высокую обобщающую способность разработанного комплекса и его готовность к интеграции в реальную инфраструктуру.

Таблица 8 – Сравнительный анализ эффективности методов обработки номенклатуры

Метод обработки данных	Точность (Macro-F1)	Полнота поиска (Recall@5)	Время обработки 1 строки, мс
Базовый метод (TF-IDF + Логистическая регрессия)	0,7214	0,6841	4,5
Предложенный каскад (ruBERT + CatBoost + FAISS) без AST	0,97	0,8912	34,5
Разработанный комплекс с методом AST	0,97	0,9803	6,2

Выводы по разделу 3

В ходе экспериментального исследования проведена комплексная практическая верификация созданных программных решений. Сформирован и сбалансирован репрезентативный набор данных объемом 99960 номенклатурных строк с распределением по 37 атомарным типам товаров. Оптимизированы параметры настройки каскада CatBoost методом рандомизированного поиска, что позволило достичь точности macro-F1 на уровне 0,97 на нижнем шаге иерархии. Подтверждена высокая вычислительная эффективность библиотеки FAISS при совместном использовании с методом динамического маскирования AST, сократившим сквозное время анализа одной позиции до 6,2 миллисекунд при сохранении полноты поиска Recall@5 на отметке 0,9803. Доказано преимущество разработанного алгоритмического стека над классическими методами векторизации со стабильным приростом точности на 24,36%.

Заключение

В выпускной квалификационной работе успешно решена прикладная задача разработки системы автоматической категоризации и семантического сопоставления потребительских товаров по неструктурированным текстовым описаниям.

На основе проведенного аналитического обзора предметной области спроектирована и реализована гибридная интеллектуальная архитектура, объединяющая векторизатор `rubert-tiny2`, трехуровневый классификатор `CatBoost` и векторный движок `FAISS`. Математически формализован пятиэтапный конвейер предобработки текстов и двухконтурная система обработки исключений с условным веб-анализом и изоляцией неопределенных строк. Авторский метод адаптивного сужения семантического пространства `AST` позволил локализовать область поиска дубликатов в оперативной памяти в рамках предсказанных классов.

Экспериментальная проверка на сбалансированном массиве из 99960 записей подтвердила высокую робастность комплекса к синтаксическому шуму и вариативности регистрового ввода. Достигнутая точность классификации типов товаров `macro-F1` составила 0,97, а скорость сквозной обработки одной номенклатурной единицы в режиме реального времени достигла 6,2 миллисекунд. Разработанное программное решение готово к интеграции в действующую ИТ-инфраструктуру торговых предприятий и маркетплейсов.

					МИВУ.01.03.02-05.000	ПЗ	Лист
Изм	Лист	№ докум.	Подп.	Дата			61

Список использованной литературы

- 1 Anderson, C. The Long Tail: Why the Future of Business is Selling Less of More. – New York: Hyperion, 2006. – 256 с.
- 2 Kuratov, Y. Adaptation of Deep Bidirectional Multilingual Transformer Model for Russian Language / Y. Kuratov, M. Arkhipov // arXiv preprint arXiv:1905.07213. – 2019.
- 3 Prokhorenkova, L. CatBoost: unbiased boosting with categorical features / L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin // Advances in Neural Information Processing Systems. – 2018. – P. 6638–6648.
- 4 Johnson, J. Billion-scale similarity search with GPUs / J. Johnson, M. Douze, H. Jégou // IEEE Transactions on Big Data. – 2019. – Vol. 7, № 3. – P. 535–547.
- 5 Реброва, О. Ю. Стандартизация и управление качеством нормативно-справочной информации на промышленных предприятиях / О. Ю. Реброва // Научно-технические ведомости СПбГПУ. Экономические науки. 2021. Т. 14, № 1. – С. 54–71.
- 6 Christen, P. Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection / P. Christen. – Berlin: Springer-Verlag, 2012. – 272 p.
- 7 Савельев, А. О. Проектирование архитектуры баз данных для систем управления мастер-данными класса MDM и PIM / А. О. Савельев // Программные продукты и системы. – 2023. – № 2. – С. 112–124.
- 8 Elmagarmid, A. K. Duplicate record detection: A survey / A. K. Elmagarmid, P. G. Ipeirotis, V. S. Verykios // IEEE Transactions on Knowledge and Data Engineering. – 2007. – Vol. 19, No. 1. – P. 1–16.
- 9 Kopcke, H. Frameworks for entity matching: A comparison / H. Kopcke, E. Rahm // Data & Knowledge Engineering. – 2010. – Vol. 69, No. 4. – P. 312–330.
- 10 Фридл, Дж. Регулярные выражения / Дж. Фридл. – Санкт-Петербург: Питер, 2018. – 608 с.

11 Salton, G. Term–weighting approaches in automatic text retrieval / G. Salton, C. Buckley // Information Processing & Management. – 1988. – Vol. 24, № 5. – P. 513–523.

12 Vaswani, A. Attention is all you need / A. Vaswani, N. Shazeer, N. Parmar (et al.) // Advances in neural information processing systems. – 2017. – P. 5998–6008.

13 Korobov, M. Morphological Analyzer and Generator for Russian and Ukrainian Languages / M. Korobov // Analysis of Images, Social Networks and Texts. – 2015. – P. 320–332.

14 Маннинг, К. Д. Введение в информационный поиск / К. Д. Маннинг, П. Рагхаван, Х. Шютце. – Москва: Вильямс, 2019. – 528 с.

15 Bentéjac, C. A formal comparison of LightGBM, XGBoost and CatBoost using a compilation of machine learning benchmarks / C. Bentéjac, A. Csörgő, G. Martínez–Muñoz // Machine Learning with Applications. – 2021. – Vol. 4. – P. 100032.

16 Shrivastava, A. Asymmetric LSH (ALSH) for sublinear time maximum inner product search (MIPS) / A. Shrivastava, P. Li // Advances in Neural Information Processing Systems (NeurIPS). – 2014. – Vol. 27. – P. 2321–2329.

17 Malkov, Yu. A. Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs / Yu. A. Malkov, D. A. Yashunin // IEEE Transactions on Pattern Analysis and Machine Intelligence. – 2020. – Vol. 42, No. 4. – P. 824–836.

18 Большакова, Е. И. Автоматическая обработка текстов на естественном языке и анализ данных / Е. И. Большакова, К. В. Воронцов. – Москва: Изд–во МГУ, 2021. – 240 с.

19 Muja, M. Scalable automatic tuning of approximate nearest neighbor methods / M. Muja, D. G. Lowe // International Conference on Computer Vision Theory and Applications (VISAPP). – 2012. – Vol. 1. – P. 331–340.

20 Reimers, N. Sentence–BERT: Sentence embeddings using Siamese BERT–networks / N. Reimers, I. Gurevych // Proceedings of the 2019 Conference on

Empirical Methods in Natural Language Processing (EMNLP). – 2019. – P. 3982–3992.

21 Japkowicz, N. The class imbalance problem: A systematic study / N. Japkowicz, S. Stephen // Intelligent Data Analysis. – 2002. – Vol. 6, No. 5. – P. 429–449.

22 Хэ, Х. Обучение на несбалансированных данных: обзор методов и подходов / Х. Хэ, Э. А. Гарсиа // Труды ИСП РАН. – 2021. – Т. 33, № 4. – С. 115–134.